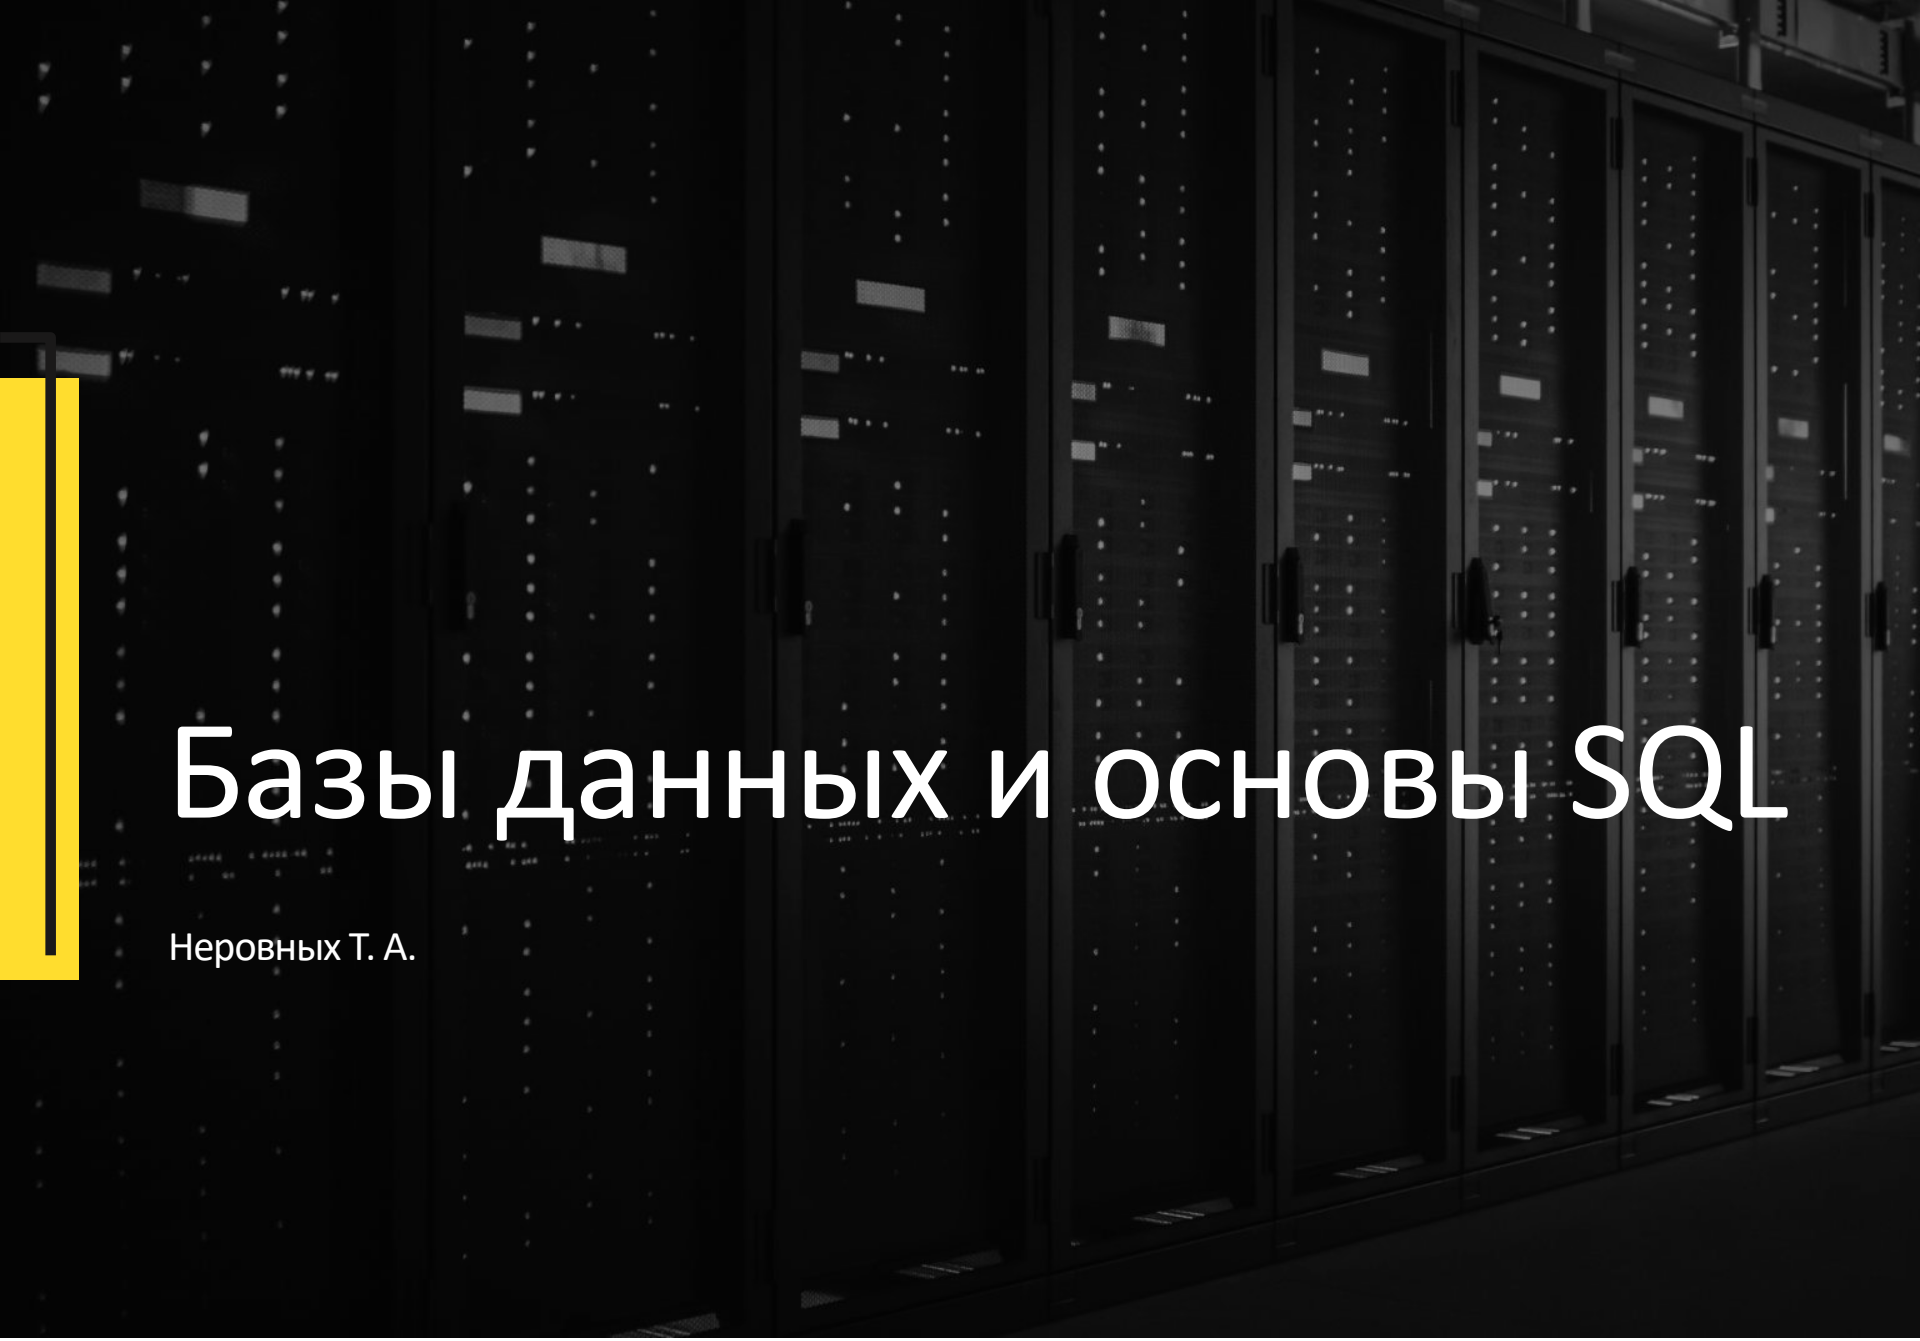

Базы данных и основы SQL

Неровных Т. А.

План

- Модель хранилища данных
- Основы SQL
- Описание витрин в базе

Откуда берутся данные?

Каждая система в рамках бизнес процесса выполняет свою роль и как следствие собирает свои собственные данные. При аналитике может потребоваться обращаться к данным с разных систем, для этого нужно понимать откуда их взять. А для ускорения работы и уменьшения нагрузки на эти системы, лучше их скопировать и положить в хранилище данных.

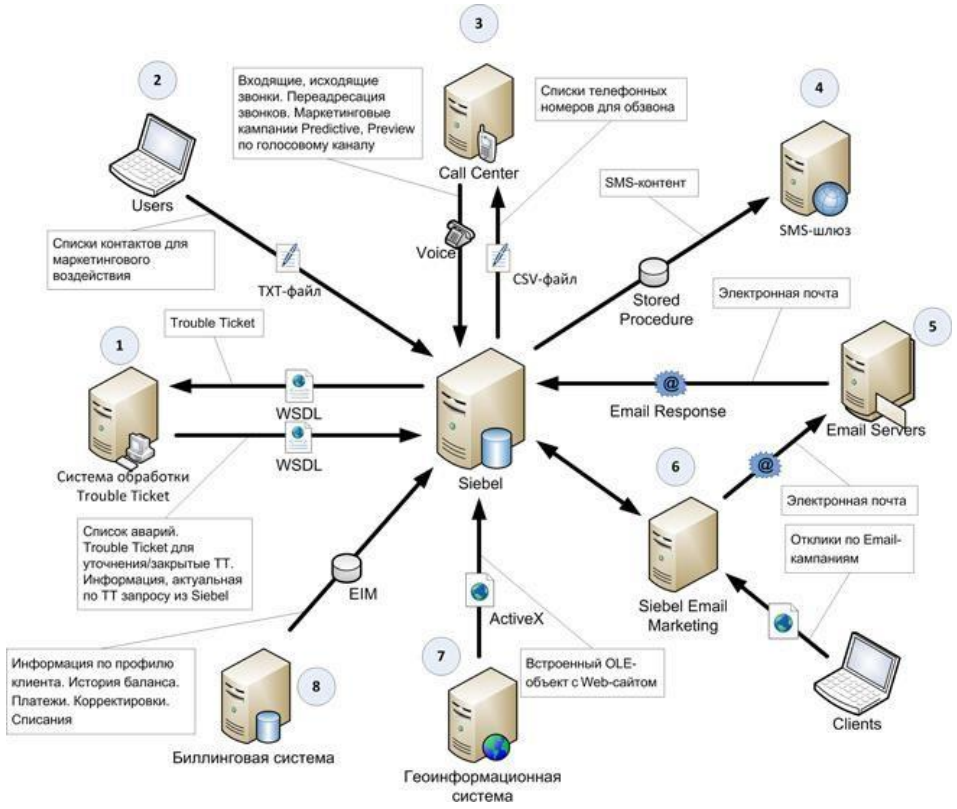

Схема с сайта http://www.tadviser.ru/

Хранение данных

Данные удобно воспринимать в формате таблиц – это достаточно наглядно, так как в рамках процесса зачастую происходят схожие “явления”, просто каждая со своим набором параметров.

Сроки таблицы – они же **записи**, разделяют эти “явления”

Столбцы таблицы – они же **поля**, служат описанием параметров этого “явления”

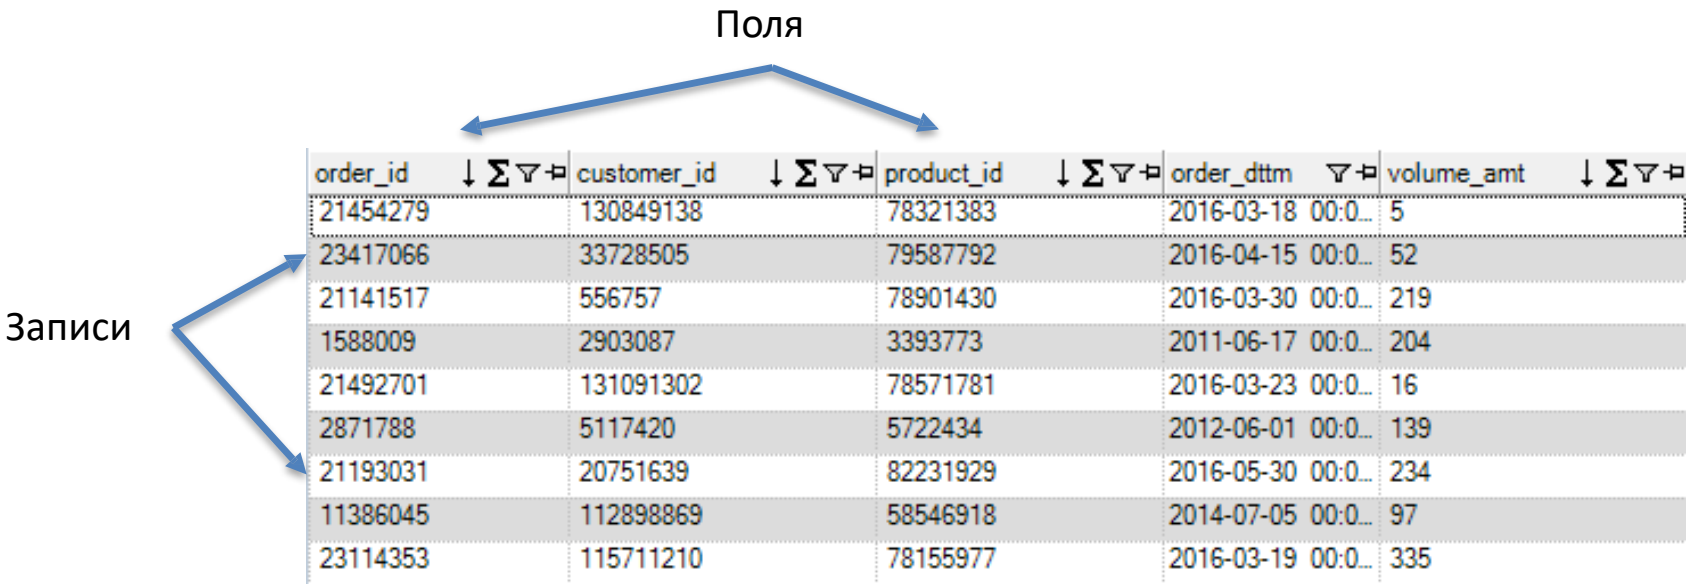

order_id	customer_id	product_id	order_dttm	volume_amt
21454279	130849138	78321383	2016-03-18 00:0...	5
23417066	33728505	79587792	2016-04-15 00:0...	52
21141517	556757	78901430	2016-03-30 00:0...	219
1588009	2903087	3393773	2011-06-17 00:0...	204
21492701	131091302	78571781	2016-03-23 00:0...	16
2871788	5117420	5722434	2012-06-01 00:0...	139
21193031	20751639	82231929	2016-05-30 00:0...	234
11386045	112898869	58546918	2014-07-05 00:0...	97
23114353	115711210	78155977	2016-03-19 00:0...	335

Модель данных

Модель данных - модель «сущность-связь» (ER-модель), описывающая набор взаимосвязанных сущностей, которые отражают потребности бизнеса в аналитике и отчетности.

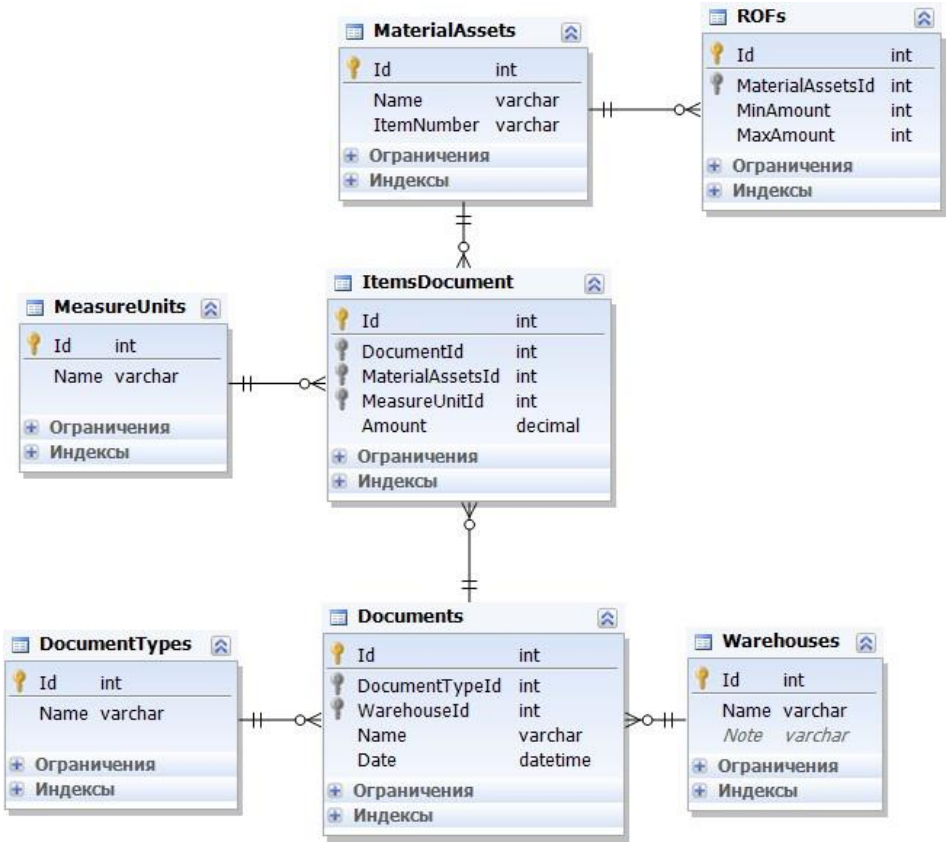

Модель данных

А еще модель данных может выглядеть вот так

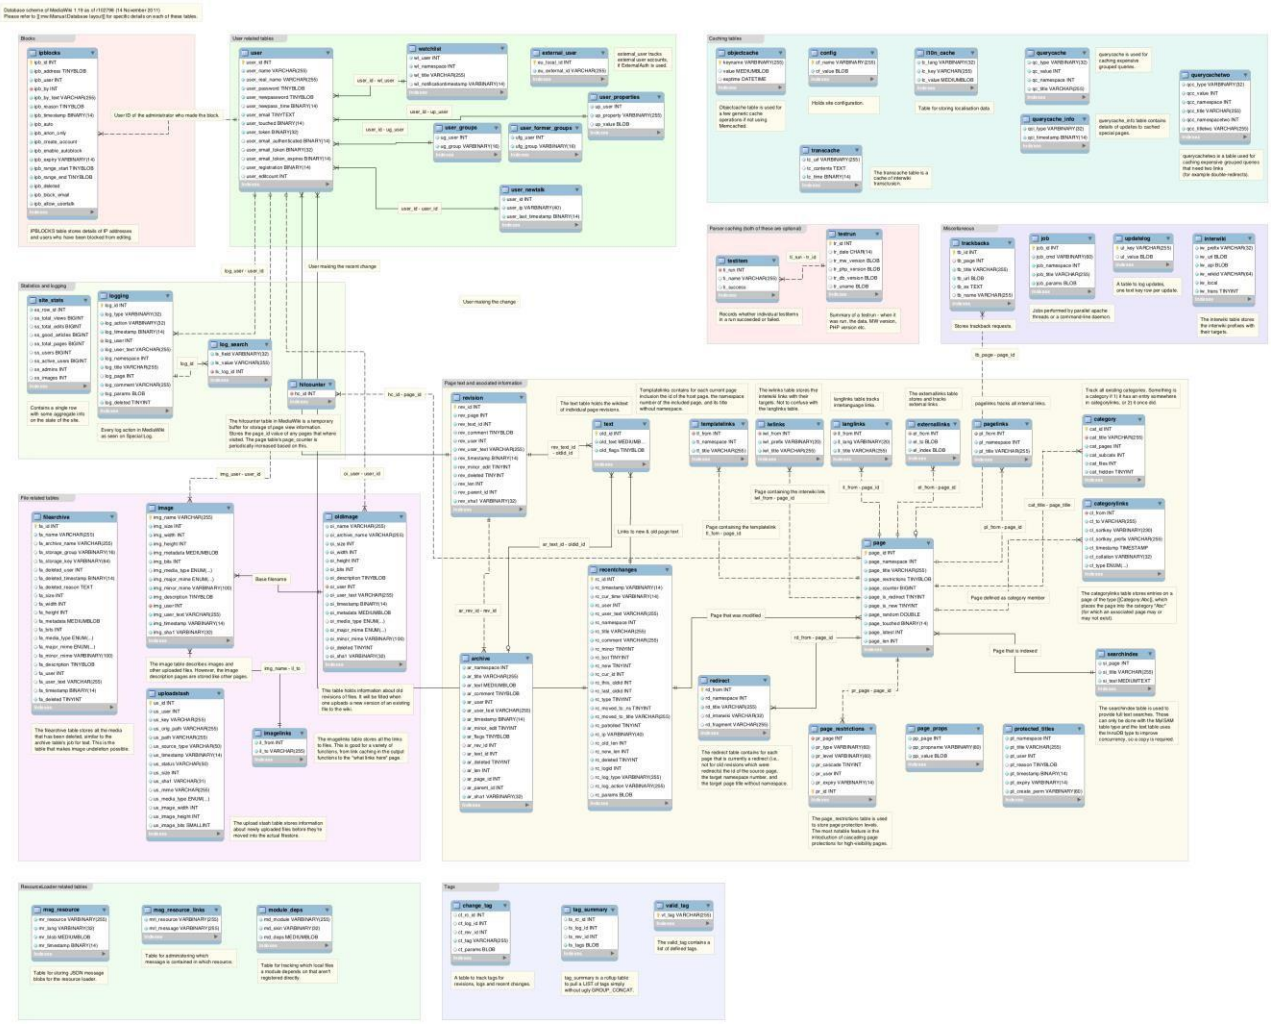

Первичные и вторичные ключи

- Первичный ключ – поле или набор полей, идентифицирующих строку в таблице:
  - недопустимо отсутствие значения;
  - все значения уникальны.
- Внешний ключ – поле или набор полей, устанавливающих связь между данными в двух таблицах. В общем случае не имеет логических ограничений, как первичный ключ.

order_id	customer_id	product_id	order_dttm	volume_amt
21454279	130849138	78321383	2016-03-18 00:0...	5
23417066	33728505	79587792	2016-04-15 00:0...	52
21141517	556757	78901430	2016-03-30 00:0...	219
1588009	2903087	3393773	2011-06-17 00:0...	204
2[illegible]	131[illegible]	78[illegible]	2016-03-23 00:0...	16
2[illegible]	511[illegible]	57[illegible]	2012-06-01 00:0...	139
21193031	20751639	82231929	2016-05-30 00:0...	234
11386045	112898869	58546918	2014-07-05 00:0...	97
23114353	115711210	78155977	2016-03-19 00:0...	335

PK FK FK

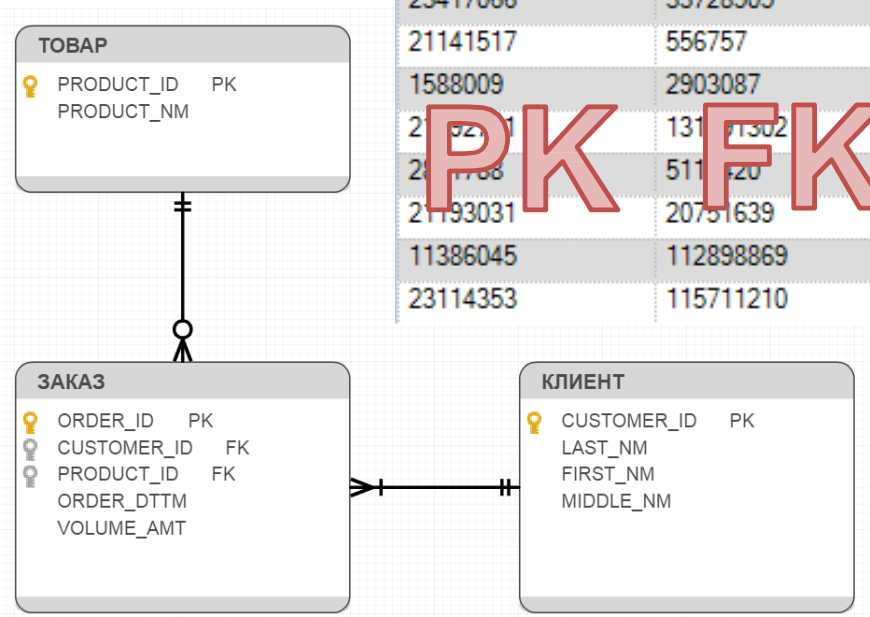

Почти случайные логотипы

SQL

SQL (Structured Query Language — «язык структурированных запросов») — **декларативный** язык программирования, применяемый для создания, модификации и управления данными в **реляционной** базе данных.

Декларати́вное программи́рование — парадигма программирования, в которой задаётся спецификация решения задачи, то есть описывается ожидаемый результат, а не способ его получения.

Реляционная БД — база данных, в которой информация хранится в виде двумерных таблиц со связями.

Язык SQL представляет собой совокупность операторов, инструкций, вычисляемых функций.

Реляционные базы данных

Почти случайные логотипы

Почти случайные логотипы

Тинькофф Квест (легенда)

Давайте предположим, что мы запускаем проект “Тинькофф Квест”.

- Открываем квесты во всей стране по франшизной системе, то есть, каждой локацией по факту владеем не мы, а наши партнеры. Каждая локация принадлежит только одному партнеру.
- Локация – это по сути помещение, при этом на одной локации может проводиться несколько квестов, если наш партнер сможет их все уместить, естественно с соблюдением всех норм и правил безопасности.
- В рамках нашего проекта, партнеры в праве продавать легенды (сценарии) своих квестов другим участникам проекта. Мы даже наняли несколько креативных агентств, которые нам написали несколько базовых легенд для квестов.
- Игрой будем называть слот в расписании. В рамках каждой отдельной игры, команде участников будет предложено пройти квест за 50 минут, кто-то справляется быстрее, а кто-то наоборот не успевает пройти. Бывает и такое, что игра может не состояться, если на нее никто не записался.
- В ходе прохождения игры, участникам будет помогать оператор.
- Также мы сделали сайт под эту идею, куда могут заходить наши клиенты. По желанию можно зарегистрироваться и оставить заявку на ту или иную игру в распиаснии.

P.S. Данная история целиком и полностью вымышленная, все совпадения с реальными личностями случайны

Тинькофф Квест (модель)

Наша модель хранилища данных будет выглядеть вот так

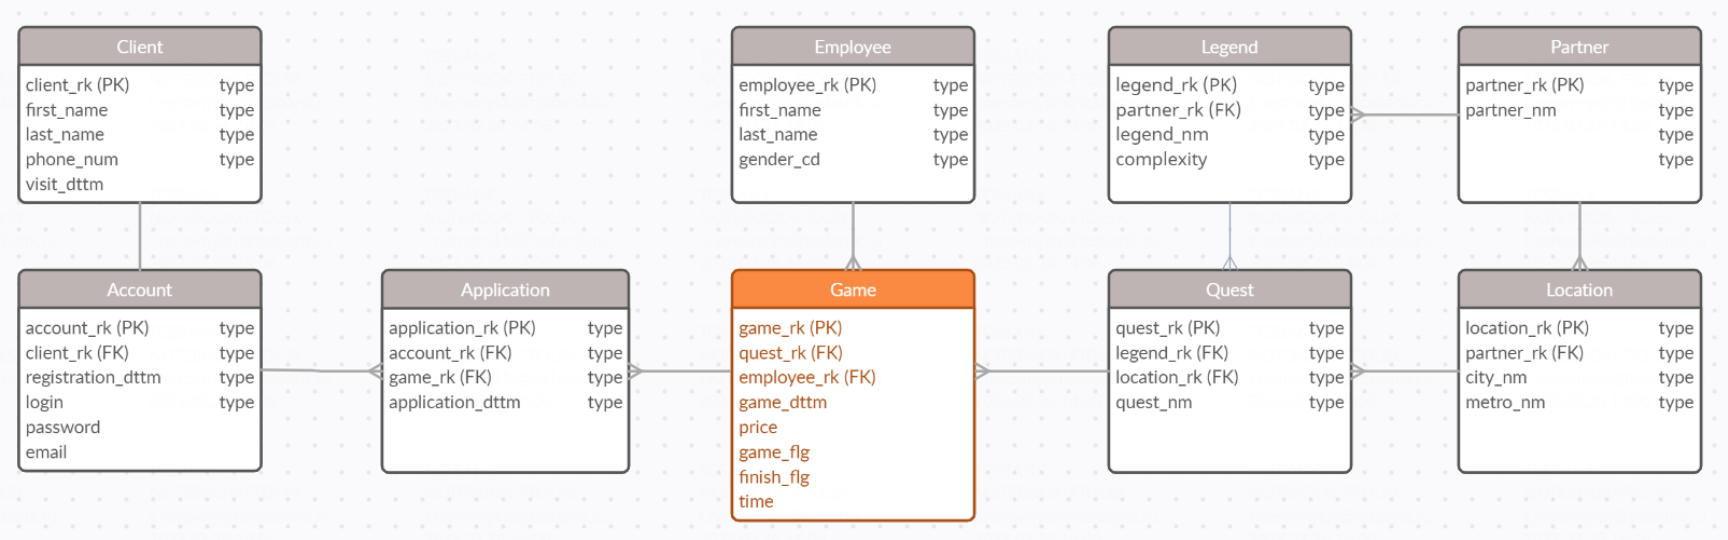

План

- Модель хранилища данных
- Основы SQL
- Описание витрин в базе

Операторы SQL

Операторы SQL делятся на:

- операторы определения данных (Data Definition Language, DDL):
  - CREATE создаёт объект базы данных (саму базу, таблицу, представление, пользователя и так далее),
  - ALTER изменяет объект,
  - DROP удаляет объект;
- операторы манипуляции данными (Data Manipulation Language, DML):
  - SELECT выбирает данные, удовлетворяющие заданным условиям,
  - INSERT добавляет новые данные,
  - UPDATE изменяет существующие данные,
  - DELETE удаляет данные;
- операторы определения доступа к данным (Data Control Language, DCL)
- операторы управления транзакциями (Transaction Control Language, TCL)

DDL


```
Create table cource_analytics.partner
(partner_rk integer,
partner_nm varchar(32))

Alter table cource_analytics.partner
add column gender_cd varchar(1)

Drop table cource_analytics.partner
```

DML


```
Insert into cource_analytics.partner (partner_rk, partner_nm) values
(1, ‘пример1’),
(2, ‘пример2’);

Update cource_analytics.partner
      set partner_nm = ‘пример3’
 where partner_nm = ‘пример2’;

Delete from cource_analytics.partner
where partner_nm = ‘пример1’;
```

SQL - запрос

Первый закон аналитики: “прежде чем начать анализировать данные, их нужно собрать”.

С этим легко можно справиться при помощи SQL запроса.

Структура запроса проста:

- **Select**
- **From**
- **Where**
- **Group by**
- **Having**
- **Order by**
- **Limit**

Операторы Select и From

Оператор Select отвечает за то, какие поля мы выводим в результат, в то время как оператор From – какие таблицы мы используем. Они должны быть в каждом запросе.

```
Select distinct
    game_dttm
From
        msu_analytics.game
```

```
Select
        *
From
        msu_analytics.employee
```

Если в операторе Select написать “*”, то будут выведены все поля, а если приписать distinct, то из всех одинаковых записей останется только одна.

```
Select
        count(*) as cnt,
        avg(time) as avg_time
From
        msu_analytics.game
```

Если в операторе Select писать только агрегирующие функции, то он выдаст единственную строку с агрегатом по всей таблице. В данном случае число строк таблицы и среднее значение времени (по тем строкам, где оно заполнено)

Приписка as позволяет поля переименовывать.

Оператор Where

Оператор Where позволяет оставить только нужные записи.

```
Select
        count(*) as cnt
From
        msu_analytics.employee
Where
        gender_cd = ‘Ж’
```

Теперь мы считаем количество не всех строк, а только тех, в которых gender_cd = ‘Ж’, что в нашем случае значит – посчитать количество девушек сотрудниц

В операторе Where можно использовать любые логические связки с использованием and, or, not

```
Select
        count(*) as cnt
From
        msu_analytics.employee
Where
        gender_cd = ‘М’
        and first_name = ‘Том’
```

Операторы Group by и Having

Оператор Group by позволяет данные группировать

```
Select
        gender_cd
        ,count(*) as cnt
From
        msu_analytics.employee
Group by
        gender_cd
```

Теперь в выводе мы увидим не 1 запись как ранее, а 2. Одна будет говорить сколько у нас сотрудников мужчин, а вторая - сколько сотрудниц женщин.

Having – это фильтрация после группировки. В данном случае, мы оставим только те записи, в которых значение поля ***cnt*** будет больше 35.

```
Select
        gender_cd
        ,count(*) as cnt
From
        msu_analytics.employee
Group by
        gender_cd
Having
        count(*) > 35
```

Оператор Order by

Оператор Order by отвечает за сортировку выводимого результата

```
Select
        gender_cd
        ,count(*) as cnt
From
        msu_analytics.employee
Group by
        1
Order by
        2 desc, 1
```

Для начала заметим, что в операторе Group by мы использовали число – это порядковый номер поля в операторе Select, то есть сгруппировали мы по полю *gender_cd*.

Сортировка же отработает по второму полю, то есть по полю *cnt*, приписка desc же означает, что сортировка будет произведена в обратном порядке (от большего к меньшему)

В операторах Group by и Order by можно использовать несколько полей, в этом случае их нужно перечислить через запятую.

Join

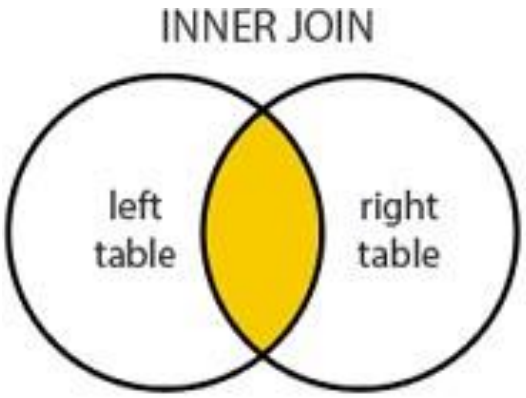
INNER JOIN
left table
right table

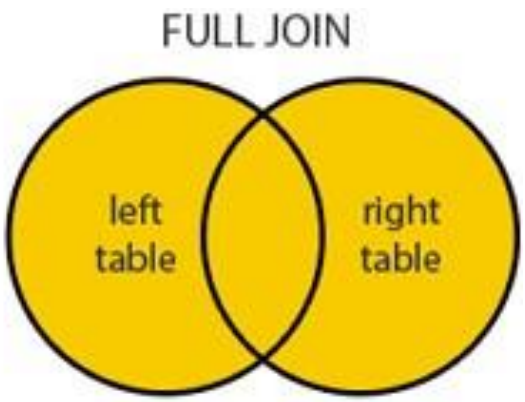
FULL JOIN
left table
right table

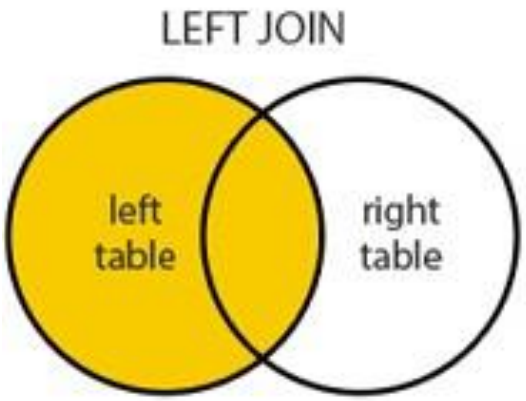
LEFT JOIN
left table
right table

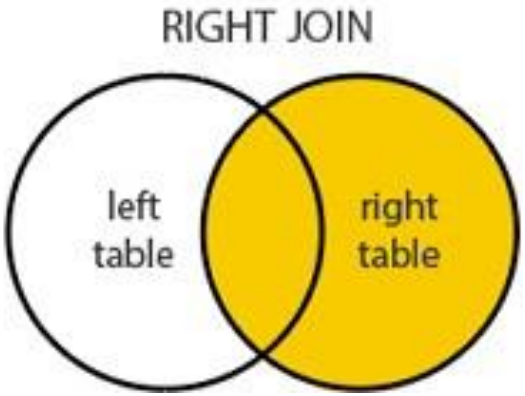
RIGHT JOIN
left table
right table

Join

Join позволяет соединять записи из разных таблиц между собой

```
Select
        a.employee_rk
        ,count(*) as cnt
From
        msu_analytics.employee a
        inner join msu_analytics.game b
                on a.employee_rk = b.employee_rk
Group by
        1
Order by
        2 desc
```

Inner join к каждой записи первой таблицы, которую мы обозначили за ***a***, подставляет записи из таблицы, которую мы обозначили за ***b*** подходящие под условия после on, при этом, на 1 запись первой таблицы может прийтись несколько записей из второй, в этом случае создастся запись на каждую комбинацию.

Если на запись из первой таблицы не нашлось записи из второй, то запись первой таблицы отфильтровывается.

Если бы мы использовали left join, то такая запись первой таблицы дополнилась бы пустой строкой из второй таблицы.

Как результат мы получили таблицу, в которой на каждого сотрудника указано на сколько игр он провел, а результат отсортирован от большего числа игр к меньшему.

Join

Можно использовать несколько Join подряд.

```
Select
        a.partner_rk
        ,a.partner_nm
        ,b.partner_nm as b_name
        ,c.partner_nm as c_name
From
        msu_analytics.partner a
        inner join msu_analytics.partner b
                on a.partner_rk = b.cpartner_rk
        left join msu_analytics.partner c  on
                a.partner_rk = c.partner_rk
                and c.partner_rk % 2 = 1
```

Подзапросы

Подзапросы позволяют нам “создавать” таблицы (в рамках запроса) и сразу к ним обращаться.

```
Select
        date_trunc(‘month’, a.dt):: date as month
        ,avg(a.cnt) as avg
From
        (
        Select
                game_dttm::date as dt
                ,count(*) as cnt
        From
                msu_analytics.game
        Group by 1
        ) a
Group by 1
```

В такой реализации мы сначала для каждого дня посчитали количество игр в расписании этого дня.

А затем усреднили это число в рамках месяца.

Достаточно часто такая конструкция используется, если нам нужно проводить несколько агрегаций подряд.

Промежуточные таблицы

Иногда удобнее создать таблицы иным способом

```
With test_table as
(
    Select *
    From msu_analytics.employee
    Where gender_cd = 'Ж'
)

Select *
From test_table
```

Сейчас мы создали таблицу test_table и теперь можем к ней обращаться неограниченное количество раз.

Промежуточные таблицы

Их тоже можно создавать несколько

```
With test_table as
(
        Select *
        From msu_analytics.employee
        Where gender_cd = ‘f’
),
test_table_2 as
(
        Select *
        From msu_analytics.employee
        Where gender_cd = ‘m’
)
Select *
From test_table
```

Оконные функции

Оконные функции не изменяют количество строк в select-е, но все равно могут обогатить записи информацией об агрегатах.

Over – создает оконную функцию.

В рамках этого окна, он группирует значения по partition by

и сортирует по order by

```
Select
        partner_rk
        ,location_rk
        ,row_number() over (partition by partner_rk order by location_rk) as num
From msu_analytics.location
```

В нашем случае мы пронумеровали для каждого партнера все его локации.

Но так можно использовать и обычные агрегирующие функции вроде sum().

Подключаемся к базе

- Устанавливаем dbeaver - https://dbeaver.io/download/
- Создаем новое подключение/соединение к серверу
- Выбираем субд Greenplum (возможно автоматически загрузятся драйвера)
- Переходим на вкладку **Главное**
- Хост: **158.160.52.106**
- Порт: **5432**
- База данных: **postgres**
- Пользователь: **student**
- Пароль: **JvLda93aA**

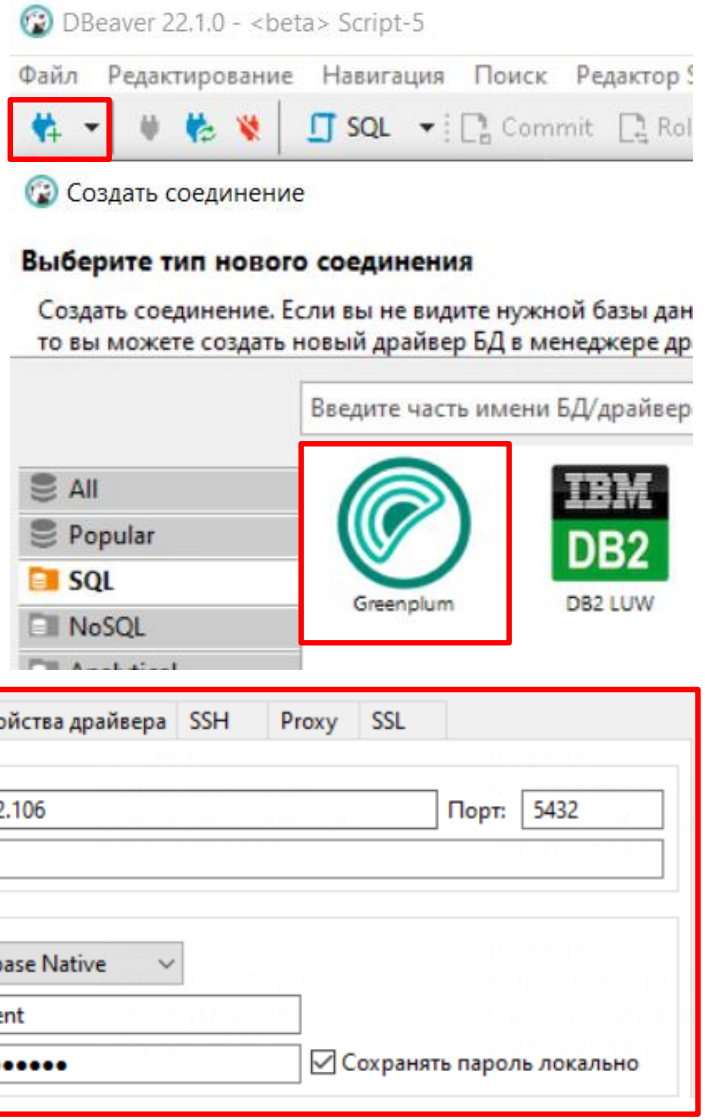

Подключаемся к базе

После этого, у вас будет доступ к данным, которые будут лежать в схеме **msu_analytics**.
Открываем окно для написания запросов и вперед.

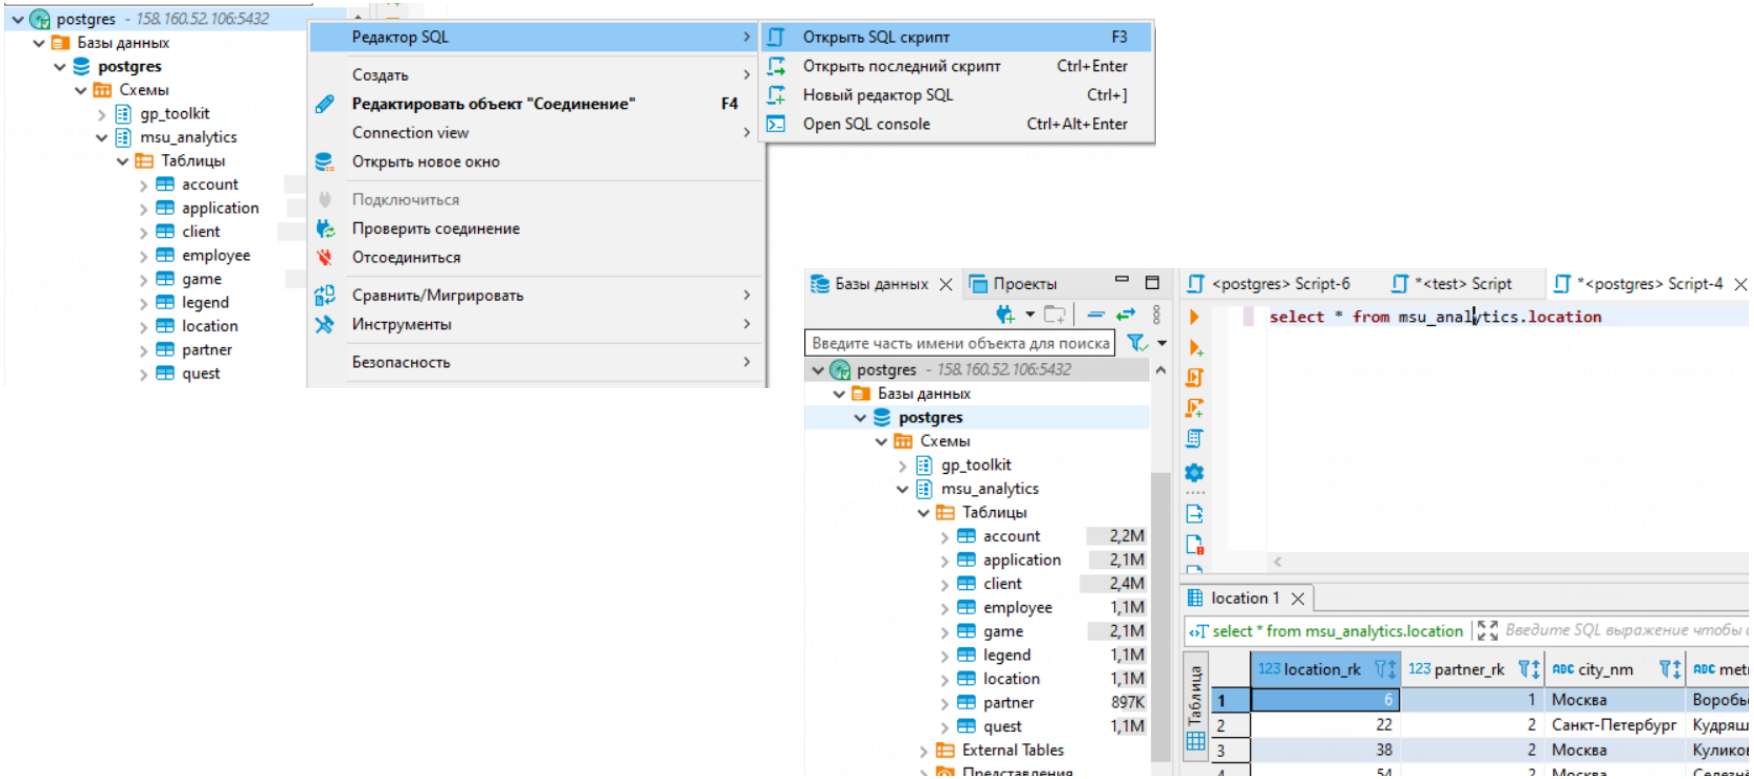

Домашнее задание

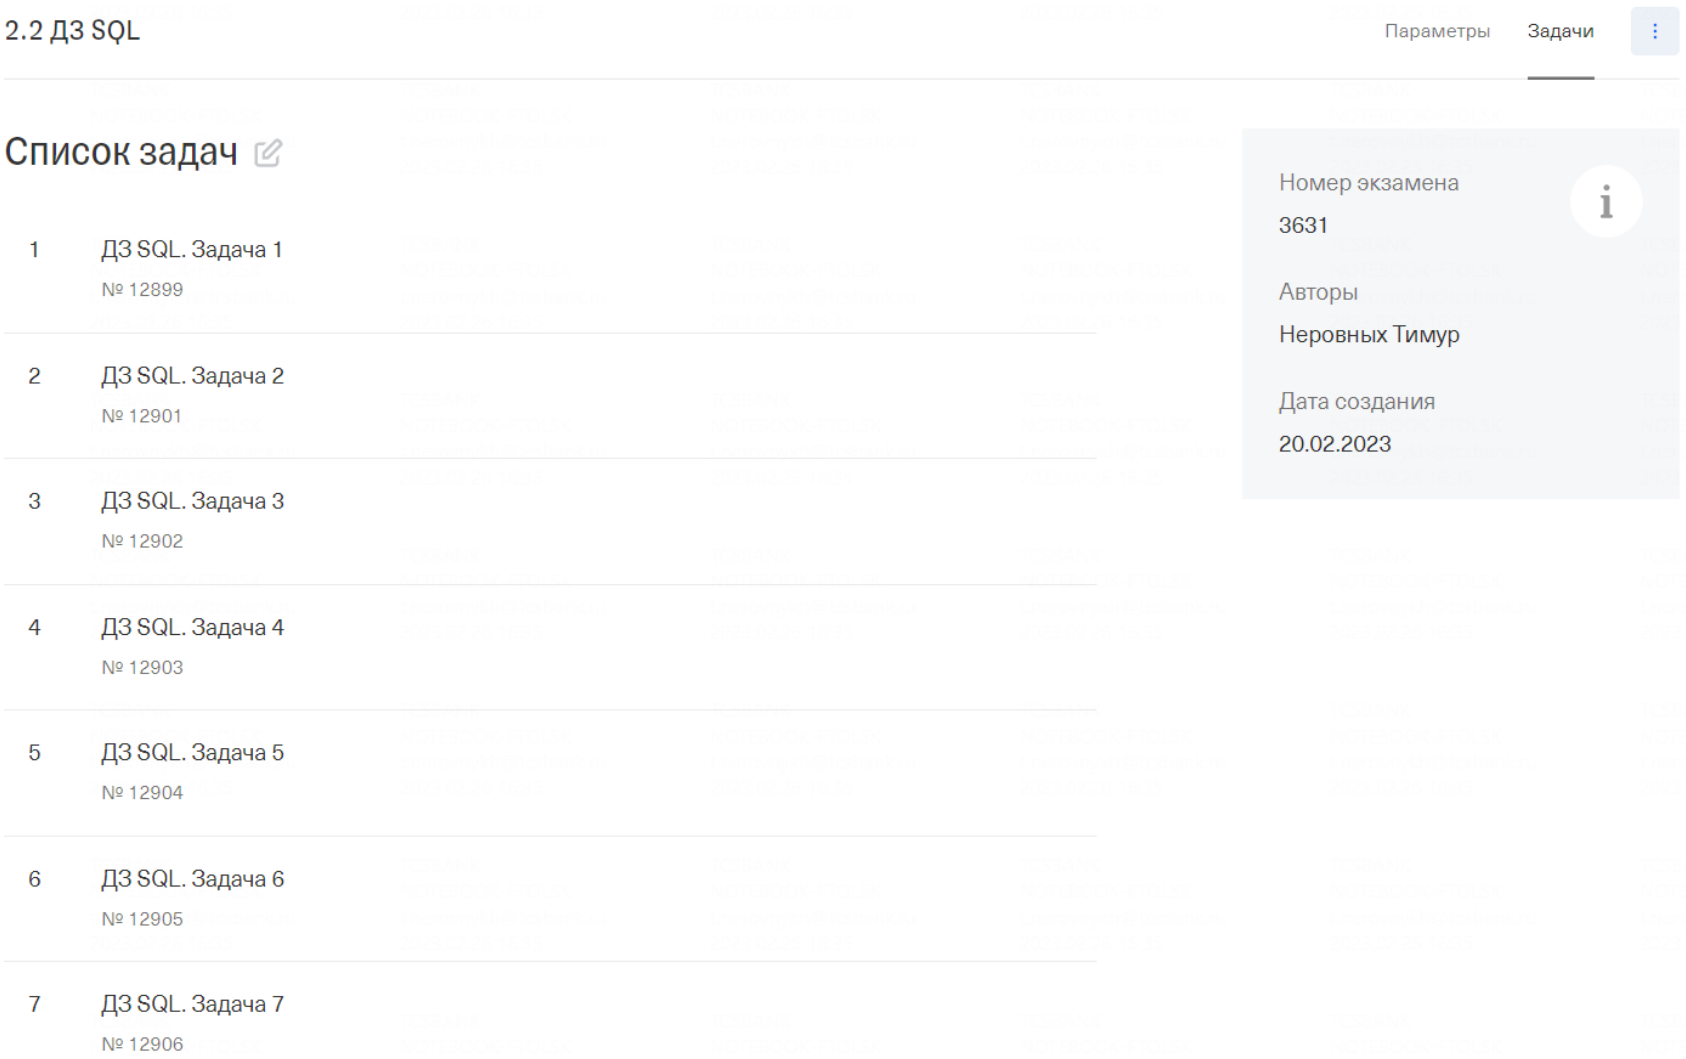

Это база

https://www.sql-ex.ru/

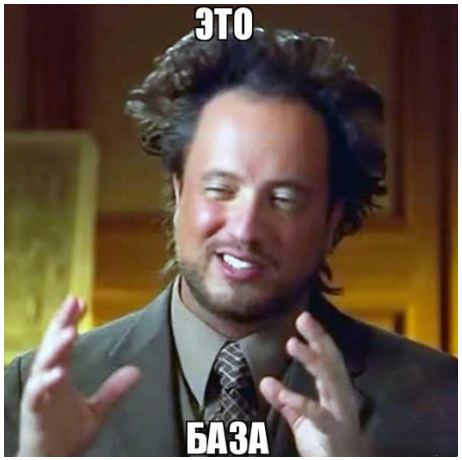

План

- Модель хранилища данных
- Основы SQL
- Описание витрин в базе

Тинькофф Квест (модель)

Наша модель хранилища данных выглядит следующим образом

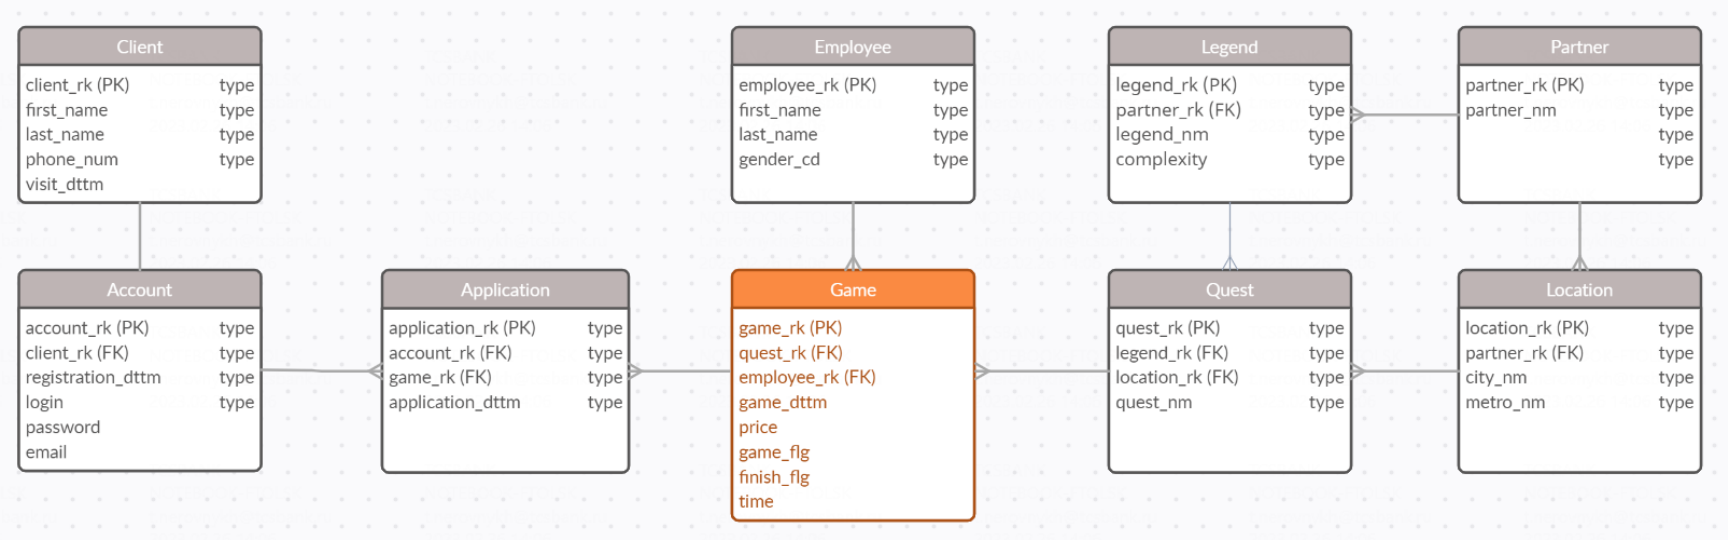

Partner

Витрина содержит информацию о наших бизнес партнерах

Название поля	Описание
Partner_rk	Ключ партнера в хранилище данных
Partner_nm	Название партнера

Location

Витрина содержит информацию о тех локациях, на которых проходят квесты нашей франшизы

Название поля	Описание
Location_rk	Ключ локации в хранилище данных
Partner_rk	Ключ партнера, которому принадлежит эта локация
City_nm	Название города, в котором расположена локация
Metro_nm	Название ближайшей станции метро к локации

Legend

Витрина содержит информацию о легендах (сценариях/сюжетах) конкретных квестов.

Название поля	Описание
Legend_rk	Ключ легенды в хранилище данных
Partner_rk	Ключ партнера, которому принадлежит авторское право на эту легенду
Legend_nm	Запатентованное название сюжета
Complexity	Сложность квеста, идущего по данному сюжету

Quest

Витрина содержит информацию о квестах, в которые могут играть наши клиенты.

Название поля	Описание
Quest_rk	Ключ квеста в хранилище данных
Legend_rk	Ключ легенды, в рамках которой играется квест
Location_rk	Ключ локации, на которой квест располагается
Quest_nm	Название квеста

Employee

Витрина содержит информацию о сотрудниках, которые проводят игры и помогают командам.

Название поля	Описание
Employee_rk	Ключ сотрудника в хранилище данных
First_name	Имя сотрудника
Last_name	Фамилия сотрудника
Gender_cd	Пол сотрудника

Game

Витрина с расписанием запланированных и состоявшихся игр (отдельных прохождений и просто слотов в расписании по играм)

Название поля	Описание
Game_rk	Ключ отдельной игры в хранилище данных
Quest_rk	Ключ квест, в рамках которого проходила игра
Employee_rk	Ключ сотрудника, который проводил игру
Game_dttm	Дата-время запланированного начала игры
Price	Стоимость игры
Game_flg	Флаг того, что игра состоялась
Finish_flg	Флаг того, что состоявшуюся игру удалось пройти
Time	Время прохождения игры

Client

Витрина содержит информацию о клиентах, посетивших наш сайт

Название поля	Описание
Client_rk	Ключ клиента в ХД
First_name	Имя клиента
Last_name	Фамилия клиента
Phone_num	Номер телефона
Visit_dttm	Дата и время, когда клиент крайний раз посещал сайт

Account

Витрина содержит информацию об аккаунтах клиентов (если у клиента есть аккаунт, значит он зарегистрировался на сайте)

Название поля	Описание
Account_rk	Ключ аккаунта клиента в ХД
Client_rk	Ключ клиента в ХД
Registration_dttm	Дата и время регистрации клиента на сайте
Login	Логин зарегистрированного клиента
Password	Пароль зарегистрированного клиента
Email	Адрес электронной почты клиента

Application

Витрина содержит информацию о заявках клиентов на иргы (заявку может оставить только авторизованный клиент, также разные клиенты могут оставить заявку на одну и ту же игру)

Название поля	Описание
Application_rk	Ключ заявки в ХД
Account_rk	Ключ аккаунта клиента в ХД
Client_rk	Ключ клиента в ХД
Application_dttm	Дата и время заявки на игру клиента